

OCR des BL et CMR

Petit projet pour rendre searchable tous les Bons de Livraison et CMR qu'on traite au quotidien sur le site CA Ressources.

Le problème

Tous nos BL et CMR sont scannés et stockés dans Google Drive. Quand je dois retrouver un document à partir d'un numéro de commande ou d'un destinataire, je suis obligé d'ouvrir les PDFs un par un parce que ce sont des images, pas du texte. Ça prend un temps fou.

Ce que fait le script

En gros : il prend les PDFs scannés, leur applique de l'OCR avec ocrmypdf, et garde la mise en page exactement comme avant. Le truc c'est qu'il rajoute une couche de texte invisible par-dessus l'image, donc visuellement c'est pareil mais on peut faire Ctrl+F dedans.

J'ai découpé en deux parties :

1. Google Apps Script — il lit le répertoire (un Google Sheet où on a les noms des BL et CMR par numéro de commande), va chercher les fichiers correspondants dans Drive et les copie dans des dossiers à part. Ensuite il crée des ZIPs par lots de 50 (Apps Script a une limite de taille sur les fichiers générés).

2. Google Colab — un notebook Python qui prend chaque ZIP, applique ocrmypdf sur tous les PDFs dedans, et te redonne un ZIP avec tout en searchable. J'ai pris Colab parce que j'ai pas Python sur mon PC du boulot et ça tourne dans le navigateur.

Pourquoi en deux étapes

J'ai d'abord essayé de tout faire dans Google Apps Script avec l'OCR natif de Google Drive, mais ça passe par une conversion en Google Doc qui casse complètement la mise en page. Pas terrible pour des documents officiels.

J'ai aussi testé les API genre OCR.space mais la version gratuite est limitée à 3 pages par PDF, et nos BL en font souvent plus de 10.

ocrmypdf c'est ce qui marche le mieux. C'est ce que les sites comme PDF24 utilisent en coulisse. Le seul souci c'est qu'il faut Python, donc Colab.

Fichiers

- google_apps_script.gs — la partie copie + zip
- colab_ocr.py — la partie OCR
- README.md — ce fichier

Volumes traités

Sur le batch de mars : 401 BL et autant de CMR. Ça tourne en quelques heures sans surveiller, pendant que je fais autre chose.

Notes

- Faut adapter les IDs dans la config du script Apps Script (Sheet, dossiers Drive)
- Pour Colab, faut bien lancer la cellule d'install en premier et attendre le redémarrage du kernel
- Si y'a des fichiers manquants dans le résultat, c'est qu'ils sont pas dans Drive ou que le nom dans le répertoire ne correspond pas exactement

Fait par Fouad El Berbri — Carrefour Europe Trading, mars 2026.